

基於常識資訊與情緒種類建立同理回應生成系統

黃薇庭 劉宇晨 徐啟倫 蘇明祥

東吳大學 資料科學系

{bindy.huang, vincent93113, laurenhsu31, huntfox.su}@gmail.com

摘要

聊天機器人基於預定義規則，難以理解使用者情感，也無法達到人類的語境能力，因此讓聊天機器人識別講述者的情緒，並且回應出符合其主題的同理回應句變成一大挑戰。本研究提出了一種情緒分類器的模型，使得生成的回應句更富有同理心，也增加情緒預測的準確度。前人的研究證實聊天機器人的訊息量以及同理心對使用者的滿意度有著正向影響，我們認為增加回應句的質量這項任務也成了一大挑戰，為了解決這個問題，我們提出了一種基於詞向量的預訓練模型，重新訓練歷史情境句，藉此提升了回應句的流暢度。研究結果表明本研究提出的 CER 模型優於其他的基線模型，除了生成出更富有同理心的回應句外，也使得生成的回應句更加流暢。

關鍵詞：自然語言處理、深度學習、常識知識圖生成

Abstract

Chatbots are based on predefined answers and rules, making it difficult to truly understand users' emotions and achieve the same contextual capabilities as humans. Therefore, it has become a big challenge for chatbots to recognize the emotions of the narrator in the conversation and respond with empathetic response sentences that match the topic. This research proposes an emotion classifier model to make the generated response sentences more empathetic and increase the accuracy of emotional prediction; previous research has confirmed that the number of messages and empathy of chatbots positively impact user satisfaction. Improving the quality of response sentences has also become a big challenge. To solve this problem, we propose a pre-trained model based on word vectors to re-train historical situation sentences, thereby improving the fluency of response sentences. The research results show that the CER model proposed in this study is better than other baseline models. In addition to generating more empathetic response sentences, it also makes the generated response sentences more fluent.

Keywords: Natural Language Processing, Deep Learning, Commonsense Knowledge Graph Generation

1. 緒論

聊天機器人增加了我們生活中的便利性，但仍有一些缺點。第一點是缺乏同理心 (Empathy) 機制，它們僅基於預定義的回答和規則運作，難以真正理解使用者的情感和需求，這可能導致回應缺乏人性化和情感連結。第二點是聊天機器人無

法達到與人類相同的語境理解能力 [1]、[2]，當使用者傳送一大段訊息時，聊天機器人可能無法從一大段話擷取使用者真正想傳達的重點，導致無法準確理解使用者的問題與需求，而這些聊天機器人沒有抓到訊息中的重點，更不會回應出具有同理心意義的回答。綜合上述對於聊天機器人的描述，識別對話中講述者的情緒，並且回應出符合其主題的同理回應句變成了一大挑戰。

根據研究 [3] 證實聊天機器人的訊息質量以及同理心對使用者的滿意度有著正向影響，我們認為增加回應句的訊息質量和富有同理心的語句，能夠讓使用者的使用經驗有所提升，因此增加回應句的質量這項任務變成了一大挑戰。基於上述問題，本研究開發一個聊天機器人能夠理解使用者傳遞的訊息中的重點，並回應出具有上下文理解和同理心意義的回答。因此，我們透過深入研究和應用自然語言處理和深度學習的相關技術，期望提升聊天機器人的智能水平，使其能夠更準確地理解使用者的需求，並給予相應的回應。透過訓練模型，我們希望讓聊天機器人能夠從大段的文字中擷取出關鍵訊息，這樣的聊天機器人將能夠提供更人性化、情感連結和滿意度高的服務，改善使用者的使用體驗。本研究將提出一種基於詞向量的預訓練模型，重新訓練歷史情境句，以提升回應句的流暢度。並提出一種情緒分類器的模型，使得生成的回應句更富有同理心，也增加情緒的預測準確度。

2. 文獻回顧

本篇章將會介紹關於自然語言處理、深度學習、同理心回應生成、常識知識圖生成、對話回應生成的相關文獻。

2.1 自然語言處理

自然語言處理是分析文本計算機化的方法，其目的是讓機器學習人類語言的語法和意義，處理並向用戶輸出。最常見的自然語言處理應用包括了，訊息檢索 (Information Retrieval) [4]、訊息提取 (Information Extraction) [5]、問題回答 (Question-Answering) [6]、文本摘要 (Text Summarization) [7] 以及機器翻譯 (Machine Translation) [8]。

2.2 深度學習

機器學習是一門人工智慧的分支，旨在使計算機系統能夠從數據中學習、改進和自主地做出決策和預測，其目標是從數據中發現模式及規律，建立模型，以這些學習經驗來處理未知的數據，進行預測、分類、分群或優化等任務，根據學習

方式和目標。而深度學習是由多個處理層組成的計算模型學習多層次的數據特徵，旨在模擬人類大腦神經元的工作方式，屬於機器學習的其中一項分支，經常被應用在語音識別 [9]、視覺物體識別 [10]、自然語言處理 [5] 等領域。

2.3 同理心回應生成

同理心一詞的定義一直以來都缺乏一個明確和一致的定義，但是大多數的學者傾向於就以下四個主題達成一致，包括理解、感受、分享、保持自我與他人區別的分化 [11]，所以在同理心這個詞中涵蓋了以上這四種主題，如圖 1。同理心回應生成 [12] 是旨利用自然語言處理和深度學習技術，在對話系統中生成能夠表現出同理心回應的方法，其目標是在建立能夠理解情感和情感需求，並生成適當且情感連結的回應句子，同理心回應生成方法涵蓋了情感分析和生成模型的結合。




圖 1 最常見的同理心主題統計結果 [11]

2.4 常識知識圖生成

常識知識圖生成 [13] 是指利用自然語言處理和知識表示技術，從大量的文本資料中自動構建常識知識圖，該領域的研究旨在建立能夠自動化構建具有常識推理能力的知識圖的方法和模型，其生成方法涵蓋了知識表示和知識擷取兩個主要方面。

在知識表示方面旨在將文本資料轉化為可計算和理解的形式，以便進行常識推理，例如：語義網 [14] 和本體論 [14]；另一種表示方法是基於向量表示的方法，例如：詞嵌入 [15] 和知識圖嵌入 [16] 等。

傳統的自然語言處理方法可以透過關鍵字擷取文本訊息，但當對話有上下文相關時，傳統方法對於機器它無法實現對話中的語意理解或精確的語境判斷。而常識知識圖就包含了這些知識，並建立了眾多常識知識庫，現在已有的常識知識圖包羅萬象，例如：ConceptNet [17]、ATOMIC

(An atlas of machine commonsense) [18]、Wikidata [19] 和 WordNet [20] 等常識知識庫。

2.5 對話回應生成

對話回應生成 [21] 是指利用自然語言處理和深度學習技術生成自然流暢且合理的回應句，以回答使用者的提問或參與的對話。對話回應生成方法包括傳統的基於規則的方法 [22] 和基於深度學習的方法 [23]。近年來，一些成功的預訓練模型 Transformer 語言模型，例如：BERT、GPT-2、Transformer-XL 等模型取得了顯著成果 [24]。

3. 系統架構

本研究將系統架構劃分為四個主要模塊，如圖 2 所示。第一個模塊是資料的預處理，我們從大規模多輪同理對話資料集 EmpatheticDialogues 中，提取所有的歷史對話語句將它們從第一句對話一直連接到最後一句的對話句，形成序列 D ，並利用 Glove Embedding 模型 [26] 提取對話句向量。再來將資料集中的所有情境句將它們從第一句的情境句一直連接到最後一句的情境句，形成序列 S ，並利用 Doc2vec Embedding 模型 [27] 擷取情境句向量。我們使用 COMET 模型得到了歷史對話語句的五種常識知識，並用 React 去區分應該要把這幾種常識知識添加到序列 D 的歷史對話句，其中 xReact 添加到 Emo 的序列 K_R 中每一句對話的末尾，而其餘的常識知識關係添加到 Cog 的序列 K_r 中每一句對話的末尾。




圖 2 CER 系統架構圖

對於 COMET 模型的訓練，我們利用 ATOMIC 中對於事件和原因發生在參與事件的人身上總共有六種常識性關係，第一種人在事件之前的意圖 (xIntent)、第二種事件發生人需要什麼 (xNeed)、第三種事件發生後人想要什麼 (xWant)、第四種事件對人的影響 (xEffect)、第五種人對事件的反應 (xReact)、第六種人的特徵屬性 (xAttr)，由於第六種 xAttr 這個類別是其他人推斷一個人的

特徵，並不包含在同理反應中，因此為了對特定事件生成常識性推理，我們增加了五個特殊的 relation token [xIntent, xNeed, xWant, xEffect, xReact] 到最後一句話的對話歷史中，採用 ATOMIC-2020 數據集上進行訓練的 COMET 模型去預測接下來回應中含有的常識句子。

第二個模塊是編碼器的輸入，接著將序列 D 輸入到 $Bert_{context}$ 得到對話表示的輸出、將序列 S 輸入到 $Bert_{situation}$ 得到情境表示的輸出、將末尾含有 React 常識知識的序列 K_R 輸入到 $Bert_{emo}$ 得到反應表示的輸出接著將其取平均、將末尾常識知識的序列 K_r 輸入到 $Bert_{cog}$ 得到常識知識表示的輸出。

第三個模塊是計算，我們將對話表示與常識知識表示串接後，輸入到 $Bert_{ctx-emo}$ 得到反應表示的輸出，情境表示與常識知識表示串接後，輸入到 $Bert_{sit-emo}$ 得到情境常識知識表示的輸出並將其與反應表示串接後，進行情緒分類丟入到 softmax 層去獲得情緒損失，對話表示與常識知識表示串接後輸入到 $Bert_{ctx-cog}$ 得到對話常識知識表示的輸出並將其與反應表示串接，再將結果自相相乘後，輸入到多層感知器 (Multilayer Perceptron, MLP) 得到預測分數的輸出。

第四個模塊是解碼器的輸出訓練，最後將預測分數輸入到 Decoder 中去進行訓練，得到回應生成的輸出，並且我們將回應生成的結果與目標句子進行標準的負對數似然損失，去與我們的字典中的詞進行詞頻比較多樣性的損失，然後我們將每次訓練的情緒損失、多樣性損失、負對數似然損失相加調整權重，將這三個損失權重總和輸入到下次的 Decoder 訓練中。

4. 實驗結果與討論

4.1 資料集

本篇論文使用的是在 Amazon Mechanical Turk 上收集的大規模多輪同理對話資料集 EmpatheticDialogues [25]，包含約 25k 的一對一開放域對話，被廣泛運用在同理對話回應生成的資料集上。資料收集方式是由兩個標記者配對，一個說話者、一個聆聽者，說話者被要求談個人的情感感受，聆聽者則是透過說話者所說的話推斷出潛在的情感，並做出善解人意的回應。我們將每個情境中的說話者及聆聽者的對話，當作模型輸入，將聆聽者的回應視為目標輸出，此數據集共有 32 個均勻分佈的情緒標籤 (surprised, excited, annoyed, proud, angry, sad, grateful, lonely, impressed, afraid, disgusted, confident, terrified, hopeful, anxious,

disappointed, joyful, prepared, guilty, furious, nostalgic, jealous, anticipating, embarrassed, content, devastated, sentimental, caring, trusting, ashamed, apprehensive, faithful)，將訓練集、驗證集、測試集切分為 8:1:1，訓練集中共有 40250 個對話，驗證集中共有 5734 個對話，測試集中共有 5255 個對話。

4.2 評估方式

本研究採用 Perplexity (PPL) 和 Distinct- n (Dist- n) 作為我們的主要自動評估指標。PPL 代表模型對其候選回應集的置信度，根據每個詞來估計一句話出現的機率，並用句子長度來做正規化，如第(1)式。 S 是句子長度， $p(w_i)$ 是第 i 個詞的機率，置信度越高，PPL 會越低，PPL 可以用來評估生成回應的總體品質。

$$PPL = P(w_1 w_2 \dots w_S)^{-\frac{1}{S}} \quad (1)$$

Distinct- n 是測量生成的回應中不同 n -gram 的比例，如第(2)式所示。 $Count(unique\ n\text{-}gram)$ 表示回應中不重複的 n -gram 數量， $Count(word)$ 表示回應中 n -gram 詞語的總數量，Distinct- n 越大表示生成的多樣性越高，通常用於評估生成的多樣性。

$$Distinct-n = \frac{Count(unique\ n\text{-}gram)}{Count(word)} \quad (2)$$

4.3 實驗結果

本研究選取了同樣都使 EmpatheticDialogues 資料集的模型來放在一起比較，並且都為 Transformer-based 的模型，包括了 MoEL、MIME、EmpDG、CEM 這幾個來當作我們的基線模型進行比較，其中我們還原較好的 CEM 模型來當作 Baseline，並且提出了 Commonsense and Emotion Recognition (CER) 模型架構，分別是 CER(a)、CER(b) 和 CER(c)，其中 CER(a) 是將預訓練好的 situation embedding 加入到我們的 situation encoder 的模型架構內，而 CER(b) 則是無添加 situation embedding，並更改情緒分類器的模型架構，最後 CER(c) 是同時將預訓練好的 situation embedding 加入到我們的 situation encoder 的模型架構內，並且更改了情緒分類器。

表 1 顯示本研究之實驗結果。本實驗的實驗參數 d 設定為 300 維，隨著我們加入了預訓練後的情境句到模型，我們給定 α 、 β 、 γ 的係數的數值範圍介於 0~3 之間。經過多次的實驗，本研究採用梯度下降法，並調整 α 、 β 、 γ 的係數，得出在 $\alpha = 0.8$ 、 $\beta = 0.29$ 、 $\gamma = 2$ 的時候，模型表現會有局部最佳解。

表 1 實驗結果

Model	PPL	Dist-1	Dist-2	Acc
MoEL	36.93	0.44	2.1	30.62%
MIME	37.09	0.47	1.9	31.36%
EmpDG	37.29	0.46	2.02	30.41%
CEM	36.11	0.66	2.99	39.11%
CER(a)	36.11	0.66	3.19	38.02%
CER(b)	36.73	0.67	3.26	40.91%
CER(c)	37.48	0.68	3.47	41.31%

表 2 列出 MoEL、MIME、EmpDG、CEM 和本研究所提之 CER(a)、CER(b)、CER(c) 模型所生成之回應句。在情緒是期待的情況下，可以了解到說話者說“本學期大學課程的最後一個星期”，可以看到所有的基線模型與 CER(a) 回應生成，都表示很一般的鼓勵、肯定或是文不對題的回答，類似不富有同理心的回應句，它們不像 CER(b)、CER(c) 有從 Knowledge 中提取到“to study”，“get a good grade”等詞語關係，想要度過本學期，這背後需要付出一定努力才能獲得好成績，因此看到 CER(b) 的回應，藉由 Knowledge 提取到說話者句中的詞語關係，同理的回答“那肯定費了不少的心力”，以此同理說話者的敘述，而 CER(c) 同樣提取到 Knowledge 提取到說話者句中的詞語關係，同理的回答“太棒了，你是不是努力的學習來達成這個目標”，與預測的句子“太棒了，你在追求哪個學位呢？”相比，CER(c) 的回應生成不但稱讚了說話者給予肯定，還同理了要達到這句話背後所要付出的努力。

表 2 模型生成回應的案例比較

Emotion	Anticipating
Dialog	This week was the last one for this
History	semester of my college courses.
Knowledge	to finish the semester, to study, to graduate, get a good grade, accomplished
MoEL	That is great! I am sure you will do well.
MIME	That is great! How did you go?
EmpDG	That is great! I bet you are proud.
CEM	That is awesome! What did you do?
CER(a)	That is great! What did you do?
CER(b)	That must have been a lot of work.

CER(c)	That is awesome! Did you study hard to make it up to you?
Gold	That is awesome, what degree are you working towards?

5. 結論與未來展望

本研究提出了 CER 模型，根據實驗結果和案例分析，我們與基線模型 MoEL、MIME、EmpDG、CEM 進行比較，我們發現 CER(b) 與 CER(c) 均表現出更富有同理心的回應句，而 CER(c) 除了生成出更富有同理心的回應句外，也使得生成的回應句更加流暢，相較於一般的機器人回答，CER(c) 在回應生成表現上更貼近人類的回應行為，這都有賴於 COMET 提取各個情境中的常識知識來幫助同理回應生成，以及我們提出的情緒分類器模型及重新預訓練的情境句添加到我們的對話訓練中。

未來，本研究希望 CER(c) 能夠被應用於精神醫療領域相關的研究上，我們期望使用者看到 CER 模型所生成出的回應句，是感到溫馨的、被理解的、有溫度的句子，當然為了增加聊天機器人的回應品質和適切性，在未來可以添加更多口語日常相關的資聊集當作外部常識知識圖譜的一環，並且持續改良情緒分類器，使得情緒的預測更為準確，讓回應生成符合其情緒的同理心回應句，在評估方面可以加入人工評估以增加結果的一致性。

Acknowledgments

The authors would like to thank the National Science and Technology Council, Taiwan, for financially supporting this research under contract no. MOST 111-2221-E-031 -003 -MY2.

參考文獻

- [1] E. Adamopoulou, and L. Moussiades, “Chatbots: History, technology, and applications,” *Machine Learning with Applications*, vol. 2, ScienceDirect, 2020, 100006.
- [2] E. Adamopoulou, and L. Moussiades, “An overview of chatbot technology,” in *Artificial Intelligence Applications and Innovations: 16th IFIP WG 12.5 International Conference, AIAI 2020, Part II 16, Neos Marmaras, Greece, June 2020*, pp. 373-383.
- [3] 王晰巍, 羅然, and 劉宇桐, “智慧圖書館線上聊天機器人使用行為影響因素及實證研究,” *情報學報*, vol. 42, no. 2, pp. 217-230.
- [4] N. R. de Oliveira, P. S. Pisa, M. A. Lopez, D. S. V. de Medeiros, and D. M. Mattos, “Identifying fake news on social networks

- based on natural language processing: trends and challenges,” *Information*, vol. 12, no. 1, 2021, pp. 38.
- [5] D. Khurana, A. Koli, K. Khatter, and S. Singh, “Natural language processing: State of the art, current trends and challenges,” *Multimedia tools and applications*, vol. 82, no. 3, 2023, pp. 3713-3744.
 - [6] F. Zhu, W. Lei, C. Wang, J. Zheng, S. Poria, and T. S. Chua, “Retrieving and reading: A comprehensive survey on open-domain question answering,” *arXiv preprint arXiv:2101.00774*, 2021.
 - [7] A. P. Widyassari, S. Rustad, G. F. Shidik, E. Noersasongko, A. Syukur, A. Affandy, “Review of automatic text summarization techniques & methods,” *Journal of King Saud University-Computer and Information Sciences*, vol. 34, no. 4, 2022, pp.1029-1046.
 - [8] H. Wang, H. Wu, Z. He, L. Huang, K. W. Church, “Progress in machine translation,” *Engineering*, 18, 2022, pp. 143-153.
 - [9] N. Chandoliker, C. Joshi, P. Roy, A. Gawas, and M. Vishwakarma, “Voice recognition: A comprehensive survey,” in *2022 International Mobile and Embedded Technology Conference (MECON)*, IEEE, 2022, pp. 45-51.
 - [10] X. Wu, D. Sahoo, and S. C. Hoi, “Recent advances in deep learning for object detection,” *Neurocomputing*, vol. 396, 2020, pp. 39-64.
 - [11] J. H. Eklund, and M. S. Meranius, “Toward a consensus on the nature of empathy: A review of reviews,” *Patient Education and Counseling*, vol. 104, no. 2, 2021, pp. 300-307.
 - [12] T. Spring, J. Casas, K. Daher, E. Mugellini, and O. Abou Khaled, “Empathic response generation in chatbots,” in *Proceedings of 4th Swiss Text Analytics Conference (SwissText 2019)*, Winterthur, Switzerland, June 2019, pp. 18-19.
 - [13] A. Bosselut, H. Rashkin, M. Sap, C. Malaviya, A. Celikyilmaz, and Y. Choi, “COMET: Commonsense transformers for automatic knowledge graph construction,” *arXiv preprint arXiv:1906.05317*, 2019.
 - [14] P. Ristoski, and H. Paulheim, “Semantic Web in data mining and knowledge discovery: A comprehensive survey,” *Journal of Web Semantics*, vol. 36, 2016, pp. 1-22.
 - [15] G. Grand, I. A. Blank, F. Pereira, and E. Fedorenko, “Semantic projection recovers rich human knowledge of multiple object features from word embeddings,” *Nature human behaviour*, vol. 6, no. 7, 2022, pp. 975-987.
 - [16] S. Choudhary, T. Luthra, A. Mittal, and R. Singh, “A survey of knowledge graph embedding and their applications,” *arXiv preprint arXiv:2107.07842*, 2021.
 - [17] R. Speer, J. Chin, and C. Havasi, “Conceptnet 5.5: An open multilingual graph of general knowledge,” in the *AAAI conference on artificial intelligence*, vol. 31, no. 1, 2017.
 - [18] M. Sap, R. Le Bras, E. Allaway, C. Bhagavatula, N. Lourie, H. Rashkin, B. Roof, N. A. Smith, and Y. Choi, “Atomic: An atlas of machine commonsense for if-then reasoning” in the *AAAI conference on artificial intelligence*, vol. 33, no. 01, 2019, pp. 3027-3035.
 - [19] D. Vrandečić, and M. Krötzsch, “Wikidata: a free collaborative knowledgebase,” *Communications of the ACM*, vol. 57, no. 10, 2014, pp. 78-85.
 - [20] G. A. Miller, “WordNet: a lexical database for English,” *Communications of the ACM*, vol. 38, no. 11, 1995, pp. 39-41.
 - [21] J. Li, W. Monroe, A. Ritter, M. Galley, J. Gao, and D. Jurafsky, “Deep reinforcement learning for dialogue generation,” *arXiv preprint arXiv:1606.01541*, 2016.
 - [22] B. Hedayatnia, K. Gopalakrishnan, S. Kim, Y. Liu, M. Eric, and D. Hakkani-Tur, “Policy-driven neural response generation for knowledge-grounded dialogue systems,” *arXiv preprint arXiv:2005.12529*, 2020.
 - [23] I. V. Serban, R. Lowe, L. Charlin, and J. Pineau, “Generative deep neural networks for dialogue: A short review,” *arXiv preprint arXiv:1611.06216*, 2016.
 - [24] F. A. Acheampong, H. Nunoo-Mensah, and W. Chen, “Transformer models for text-based emotion detection: a review of BERT-based approaches,” *Artificial Intelligence Review*, 2021, pp. 1-41.
 - [25] H. Rashkin, E. M. Smith, and Y. L. Boureau, “Towards empathetic open-domain conversation models: A new benchmark and dataset,” *arXiv preprint arXiv:1811.00207*, 2018.
 - [26] J. Pennington, R. Socher, and C. D. Manning, “Glove: Global vectors for word representation,” in the *2014 conference on empirical methods in natural language processing (EMNLP)*, 2014, pp. 1532-1543.
 - [27] A. Kulkarni, A. Shivananda, A. Kulkarni, and A. Shivananda, “Converting text to features,” *Natural Language Processing Recipes: Unlocking Text Data with Machine Learning and Deep Learning Using Python*, A. Kulkarni, and A. Shivananda, Eds. Apress, Berkeley, CA, 2021, pp. 63-106.